

Informe técnico

Cerberus: preguntas y respuestas sobre derecho colombiano

Equipo P34K Universidad de los Andes

3 de octubre de 2026

Cerberus usa una arquitectura RAG: busca información en un corpus jurídico y la entrega a Qwen para responder. Esta descripción corresponde a Mark 50.

1. Arquitectura

El sistema tiene dos recorridos. Primero prepara los documentos y construye los índices. Después, cada pregunta usa esos índices para reunir la evidencia que leerá el modelo. BGE-M3 representa los textos, el reranker selecciona los pasajes y Qwen redacta la respuesta. [5]

Etapas	Entrada y resultado
Preparación del corpus	
Extracción	De los originales HTML y PDF se obtiene el texto; se usa OCR cuando hace falta. Se conservan documento, fuente, fecha y hash.
Segmentación	El artículo se mantiene como referencia. Para buscar se crean ventanas de 512 tokens, con 64 de solapamiento; las sentencias se organizan por párrafos.
Indexación	BGE-M3 convierte cada ventana y su encabezado en un vector. FAISS guarda los vectores; SQLite guarda textos y metadatos, y permite la búsqueda BM25. Núcleo y complemento tienen índices separados.

Respuesta a una pregunta

Entrada	Se recibe la pregunta, sus opciones y su formato. El área jurídica puede aportar el nombre de un código a la consulta. Las respuestas esperadas quedan fuera.
Búsqueda	FAISS encuentra pasajes por significado y BM25 por coincidencias de palabras, leyes o artículos. RRF combina ambas listas, con $k = 60$, y devuelve 50 candidatos por búsqueda.
Selección	Se eliminan candidatos duplicados. El reranker lee cada pasaje junto con la pregunta y lo puntúa. Se seleccionan hasta diez, con ajustes por tipo de fuente y orden jurídico.
Generación	Qwen recibe la pregunta y los pasajes seleccionados. En cerradas elige A–D y justifica; en texto libre redacta según el esquema solicitado.
Revisión y salida	Se contrastan las citas con los pasajes y se eliminan oraciones con referencias sin respaldo. Se valida el JSON. La salida conserva la respuesta, las citas y los pasajes recuperados.

La búsqueda puede repetirse antes de redactar. Si la evidencia es débil, se consulta el complemento. El mismo Qwen también revisa si los cinco primeros pasajes bastan para responder. Si hacen falta datos, una reformulación basada en esos pasajes o varias subconsultas permiten buscar de nuevo. Los resultados se unen a los anteriores y vuelven a pasar por el reranker. [5]

Qwen recibe hasta 5.500 tokens de evidencia. Cuando cabe, una ventana se amplía al artículo completo para conservar su contexto. Los identificadores y las posiciones en el documento permiten volver al texto de origen. La interfaz y el comando de entrega usan la misma configuración. [5]

El manifiesto registra 32.617 documentos; 32.609 están marcados como aptos para búsqueda. Cada registro conserva la procedencia del documento. [4]

2. Encoder, decoder y configuración

Uso	Modelo / revisión	Elección
Encoder	BAAI/bge-m3 5617a9f6	Multilingüe. Vectores normalizados de 1.024 dimensiones. [1]
Decoder	Qwen/Qwen3-8B b968826d	Permite limitar el razonamiento en cerradas y redactar las demás sin <i>thinking</i> . [2]
Reranker	BAAI/bge-reranker-v2-m3 953dc6f6	Evalúa la pregunta y el pasaje juntos. Multilingüe; ejecución en FP16. [3]

Usamos BGE-M3 para encontrar textos aunque la pregunta no repita sus palabras. BM25 conserva las coincidencias exactas y el reranker revisa qué pasajes responden al caso. Qwen queda a cargo de redactar. La selección responde al idioma y a la memoria disponible; todavía falta una comparación controlada entre modelos. [1–3, 5]

Parámetro	Valor
Equipo	RTX 4090 de 24 GB, según las pruebas documentadas.
Precisión	Decoder BF16; NF4 de 4 bits si falla la carga.
Contexto	5.500 tokens de evidencia; hasta 6.500 de entrada.
Generación	Sin muestreo, un haz, semilla 17. Hasta 700 tokens ordinarios.
Cerradas	Hasta 1.536 tokens de razonamiento; selección A–D por logits FP32.
Búsqueda adicional	Umbral del reranker: 0,25. Juicio de suficiencia: 0,5 sobre los cinco primeros pasajes. HyDE desactivado.
Mark 50	Orden jurídico del contexto, redacción IRAC y semiabiertas de dos a cuatro oraciones.

Los límites de contexto y generación permiten acotar el texto que procesa el modelo y el tiempo por pregunta. En cerradas reservamos más tokens para razonar; en texto libre pedimos una respuesta breve con su fundamento. La generación sin muestreo ayuda a repetir las respuestas con la misma configuración. [5]

Las citas se contrastan con los diez primeros pasajes. La abstención cubre falta de evidencia, contexto sin pasajes, texto libre sin respaldo normativo detectable o salida inválida. Con evidencia parcial, el sistema suele responder. [5]

3. Resultados de la muestra

La muestra tiene 50 preguntas: 15 cerradas, 30 semiabiertas y 5 abiertas. Estos son los resultados de Mark 46 registrados en el README, con el índice nuevo. [6]

Componente	Puntos	Máximo
Exactitud en cerradas	17,33	20
Calidad de citación	17,96	20
Abstención calibrada	9,07	10
Total sin RAGAS	44,36	50

En Mark 46 acertamos 13 de las 15 cerradas. El recall ponderado de citas fue 0,898 y el extractor no encontró referencias sin respaldo. No hubo abstenciones, así que esta corrida todavía dice poco sobre cómo responde el sistema cuando falta el fundamento en el corpus. [6]

Medida	Resultado	Fuente
Mark 50, sin RAGAS	44,77/50	Comentarios de configuración; reporte completo ausente. [5]
Mark 50, RAGAS local	13,87/30	Estimación local; no equivale al juez oficial. [5]
Tiempo medio	19,5 / 19,7 s	Mark 46 / Mark 50, según documentación. [5, 6]

Mark 50 registra una mejora pequeña en la nota sin RAGAS. La estimación local ayuda a revisar el texto libre, pero aún falta la evaluación completa del juez oficial. Los reportes no están en esta copia; las cifras vienen de la documentación y no se suman entre versiones o evaluaciones distintas. [5, 6]

Pregunta	Observación de la bitácora [6]
58	Año incorrecto en una opción. El normalizador mejora la respuesta en Mark 46.
453	El orden de las citas dejaba fuera precedentes relevantes. Mark 49 registra una mejora.
253 y 679	Dificultad para seleccionar y aplicar el fundamento en casos de accidente laboral y datos de salud.

Estos casos muestran que hace falta encontrar el fundamento, interpretarlo y conservar sus datos de citación. Revisar la respuesta junto con los pasajes permite ver dónde se perdió la información; la nota total no muestra ese recorrido. [6]

4. Limitaciones

Aspecto	Pendiente
Evaluación	Ajustamos sobre las mismas 50 preguntas. Falta validación independiente sobre las 992 y una corrida completa del juez oficial RAGAS.
Citas y corpus	Una norma presente en el pasaje no asegura que respalde la conclusión. Puede faltar información o haber errores de OCR.
Abstención	Tiende a responder con evidencia parcial. Falta probar mejor las consultas fuera del corpus.
Vigencia	Las marcas de derogación y el año de una sentencia ayudan a ordenar, pero requieren revisión jurídica.
Decoder	El proyecto registra 8.190.735.360 parámetros; falta confirmar su admisibilidad frente al límite nominal de 8.000 millones. BF16 y NF4 requieren mediciones separadas.
Reproducción	Esta copia no incluye índice, corpus procesado ni salidas. No permite repetir aquí las pruebas.

Por ahora, los resultados describen la muestra usada durante el desarrollo. Para valorar el sistema en otros casos

hacen falta preguntas nuevas y una revisión del contenido jurídico, además de comprobar las citas.

Fuentes

- [1] BAAI. BGE-M3.
- [2] Qwen. Qwen3-8B.
- [3] BAAI. BGE-reranker-v2-m3.
- [4] `corpus_manifest.json`.
- [5] `src/legalrag/config.py`, `src/legalrag/pipeline.py` y módulos de indexación, recuperación, generación y citas.
- [6] `README.md` y `MARKS.md`.

Las fichas describen los modelos. El código permite revisar la arquitectura y la configuración; el manifiesto y la bitácora documentan el corpus y las pruebas.